

UNIVERSIDAD SURCOLOMBIANA

Facultad de Ingeniería · Programa de Ingeniería de Software

ELECPREVIS

Previsión del consumo eléctrico residencial y escenarios de eficiencia energética mediante Machine Learning

Entregable 1 · Propuesta, Estado del Arte y Marco Teórico (Hito 1)

Ciencias de la Computación II · Electiva en Ingeniería Aplicada II

Grupo 8 · Energía e Industria 4.0

Juan Diego Montenegro Segura · 20252238299

Sofía Montaña · 20212200775

Nicolás Mosquera Perdomo · 20231214786

Neiva (Huila), Colombia

2026

Control del documento

Versión	Fecha	Descripción	Elaboró
v1.0	Agosto de 2026	Versión inicial: formulación del problema, revisión bibliográfica, estado del arte, marco teórico y metodología.	Grupo 8
v2.0	Agosto de 2026	Ajuste a 20 referencias, formato IEEE estricto y matriz de antecedentes.	Grupo 8
v3.0	Septiembre de 2026	Ajustes metodológicos: resolución temporal de 30 minutos, horizonte de predicción unificado, comparación de cuatro modelos y corrección de las referencias.	Grupo 8
v3.1	Septiembre de 2026	Revisión de redacción general.	Grupo 8

Contenido

Control del documento	2
Contenido	3
1. Formulación del problema de investigación	5
1.1 Contexto	5
1.2 Planteamiento del problema	5
2. Objetivos	6
2.1 Objetivo general	6
2.2 Objetivos específicos	6
3. Preguntas de investigación	6
4. Justificación y selección del dataset	7
5. Revisión bibliográfica	8
6. Estado del arte	8
6.1 El problema del forecasting eléctrico	8
6.2 Métodos estadísticos como línea base	8
6.3 Machine learning basado en árboles	9
6.4 Deep learning para series temporales	9
6.5 Modelos híbridos e interpretables	9
6.6 Forecasting residencial y eficiencia energética	9
6.7 Aplicaciones en renovables, redes y movilidad eléctrica	10
6.8 Síntesis de las familias de métodos	10
6.9 Matriz de antecedentes	10
6.10 Brecha de conocimiento y contribución del proyecto	11
7. Marco teórico / conceptual	12
7.1 Consumo eléctrico y el dataset UCI	12
7.2 Series temporales y estacionalidad	12
7.3 Horizonte de predicción y resolución temporal	12
7.4 Rezagos y ventana deslizante	13
7.5 Modelos de regresión supervisada	13
7.6 Validación temporal y prevención de data leakage	13
7.7 Métricas de evaluación	14
8. Metodología propuesta	14

9. Alcance y limitaciones	15
9.1 Alcance	15
9.2 Limitaciones	15
Referencias	16

1. Formulación del problema de investigación

1.1 Contexto

La digitalización de los sistemas eléctricos ha incrementado considerablemente la cantidad de información disponible sobre el consumo energético. Sin embargo, esa información no siempre se traduce en herramientas útiles para los usuarios. Los medidores inteligentes y la expansión de las renovables generan datos con una resolución que hace veinte años no existía, y con ellos creció la posibilidad de anticipar cuánta energía se consumirá en las próximas horas. En las redes inteligentes, esa previsión de demanda es lo que permite planificar generación, operar el mercado y activar programas de respuesta a la demanda [1].

Colombia vive esa transición con particular intensidad. La Ley 2099 de 2021 impulsó las energías renovables y regiones como el Huila, con una radiación media en Neiva cercana a los 4,2 kWh/m² por día, se convirtieron en polos de generación solar. La generación renovable es variable, y para integrarla bien hace falta conocer con anticipación el comportamiento del consumo. Ahí aparece la brecha que motiva este proyecto: los hogares y pequeños comercios generan datos de consumo, pero casi nadie les devuelve información útil. La Industria 4.0 ofrece las técnicas (sensórica, datos, aprendizaje automático) para cerrar ese ciclo, y la literatura reciente ya muestra aplicaciones concretas en gestión energética de edificios y hogares [2], [3].

El dataset con el que trabajaremos, Individual Household Electric Power Consumption del repositorio UCI de la Universidad de California, registró minuto a minuto el consumo de una vivienda en Sceaux, Francia, entre diciembre de 2006 y noviembre de 2010 [4]. Son 2.075.259 mediciones de potencia activa y reactiva, tensión, intensidad y tres submediciones asociadas a grupos de cargas domésticas. Es un ejemplo de lo que hoy es posible medir y, al mismo tiempo, de lo poco que se aprovecha: hay datos abundantes y la mayoría de los usuarios no sabe qué patrones esconde su consumo ni cuánto podría reducir.

1.2 Planteamiento del problema

El problema puede analizarse desde dos ángulos. El primero es técnico. Predecir consumo eléctrico a partir de series de alta frecuencia implica lidiar con volumen, ruido, valores faltantes y patrones que se repiten por hora, por día de la semana y por estación. Los métodos estadísticos clásicos suponen linealidad y fallan ante esa complejidad; los modelos de machine learning y las redes profundas la manejan mejor, pero su desempeño depende de la resolución, el horizonte, las variables y el protocolo de evaluación elegidos [5]. No existe un único modelo dominante: la literatura coincide en que hace falta comparación rigurosa bajo condiciones idénticas.

La segunda cara es práctica. La información que sale de los medidores rara vez llega al usuario como conocimiento accionable. Saber que el consumo sube en la noche no basta si no se puede identificar dónde se concentra el gasto (cocina, lavandería, calentamiento de agua) ni qué pasaría si se redujera. Los datos del dataset UCI son observacionales: no contienen experimentos de intervención, así que no permiten afirmar que una medida específica produzca un ahorro

causal. Los datos sí sirven para modelar el consumo, encontrar patrones y simular escenarios hipotéticos de reducción.

Se debe diferenciar el alcance geográfico de los resultados. La motivación del proyecto se apoya en el contexto colombiano y en el potencial energético del Huila, pero la validación experimental se hará con datos históricos de una vivienda en Francia. Los resultados serán un estudio de caso residencial, no conclusiones estadísticas sobre hogares de Neiva. La metodología, pero así mismo, está pensada para transferirse a datos locales cuando existan.

La pregunta principal que orienta la investigación es:

¿Qué modelo de machine learning predice mejor el consumo eléctrico residencial a 30 minutos entre alternativas de distinta complejidad, y en qué medida el análisis de las submediciones permite interpretar esas predicciones en escenarios de eficiencia energética?

2. Objetivos

2.1 Objetivo general

Desarrollar y evaluar una metodología de previsión del consumo eléctrico residencial que permita comparar modelos de diferente complejidad, identificar patrones temporales y construir escenarios hipotéticos de eficiencia a partir de las submediciones del conjunto de datos UCI Individual Household Electric Power Consumption.

2.2 Objetivos específicos

1. Preparar una serie temporal a intervalos de 30 minutos mediante limpieza, tratamiento documentado de valores faltantes y construcción de variables temporales y rezagadas, conservando más de 35.000 observaciones válidas para el modelado.
2. Caracterizar los patrones horarios, semanales y estacionales del consumo mediante análisis exploratorio, visualización y descomposición de la serie temporal.
3. Implementar y comparar regresión lineal, random forest, XGBoost y LSTM bajo un mismo horizonte de predicción y un protocolo de validación temporal, usando MAE, RMSE, R^2 y sMAPE.
4. Analizar las submediciones asociadas a grupos de cargas domésticas y simular escenarios de reducción bajo supuestos explícitos, estimando su efecto potencial sobre el consumo agregado sin atribuir causalidad.
5. Integrar el modelo seleccionado y los resultados del análisis en un prototipo que permita visualizar el histórico, la predicción de los siguientes intervalos y los escenarios simulados.

3. Preguntas de investigación

Cuatro preguntas guían el análisis con Python. Cada una puede responderse con datos y con un método verificable:

N.º	Pregunta	Qué analizaremos con Python
1	¿Qué patrones horarios, semanales y estacionales presenta el consumo y qué relación mantienen con las variables eléctricas y las submediciones disponibles?	Análisis exploratorio, correlaciones, descomposición y visualización de la serie.
2	¿Cuál de los modelos regresión lineal, random forest, XGBoost y LSTM predice mejor el siguiente intervalo de 30 minutos bajo un mismo protocolo temporal?	Construcción de rezagos, entrenamiento y evaluación walk-forward con MAE, RMSE, R ² y sMAPE.
3	¿Cómo pueden usarse las submediciones para simular escenarios de reducción y estimar su efecto sobre el consumo agregado?	Escenarios contrafactuales con reducciones porcentuales y supuestos reportados explícitamente.

Tabla 1. Preguntas de investigación del proyecto ElecPrevis.

4. Justificación y selección del dataset

La selección del dataset respondió a tres criterios: volumen suficiente para el procesamiento masivo que exige el curso, pertinencia con la línea de Energía e Industria 4.0 y facilidad de acceso y reproducibilidad para todo el equipo.

Criterio	Dataset UCI Household Electric Power	Por qué se eligió
Volumen	2.075.259 mediciones minuto a minuto (dic. 2006 a nov. 2010)	El remuestreo a 30 minutos produce 69.177 intervalos potenciales y 68.324 con potencia activa válida (conteo verificado sobre el archivo descargado). Supera con margen el mínimo de 35.000 registros.
Variables	Fecha/hora, potencia activa y reactiva, tensión, intensidad y tres submediciones de cargas	Las submediciones permiten estudiar circuitos de cocina, lavandería y calentamiento de agua, sin confundirlos con zonas completas ni con electrodomésticos individuales.
Formato	CSV plano, abierto, sin autenticación	Descargable y reproducible por cualquier integrante; evita depender de APIs o de plataformas que exigen inicio de sesión.
Trayectoria	Dataset clásico del repositorio UCI, usado en cientos de estudios y tutoriales [4]	Amplia documentación y resultados comparables; facilita contrastar nuestros resultados con la literatura.

Tabla 2. Criterios de selección del dataset.

Se evaluaron dos alternativas antes de decidir. Solar Power Generation Data, de Kaggle, quedó descartado por dos motivos: su volumen ronda el límite del mínimo exigido y su descarga exige

autenticación, lo que dificulta la reproducibilidad. La API de radiación solar de la NASA (NASA POWER) aporta contexto valioso de Neiva, pero obliga a construir el dataset desde una API y no contiene consumo eléctrico real. Se decidió entonces usar el dataset UCI como fuente principal y dejar la radiación de Neiva como referencia de contexto en la discusión final.

Una nota sobre la resolución. El remuestreo horario deja aproximadamente 34.500 registros, apenas por debajo del mínimo que pide la rúbrica. Por eso trabajaremos a 30 minutos: duplica el número de observaciones, sigue siendo una resolución manejable y deja margen de sobra frente al requisito. En el Entregable 2 se justificará esta decisión con el conteo final ya aplicado a los datos limpios.

5. Revisión bibliográfica

La búsqueda se concentró en IEEE Xplore, SpringerLink, ScienceDirect y MDPI, combinando los términos "residential electricity load forecasting", "household energy consumption prediction", "temporal validation", "XGBoost", "random forest" y "LSTM". Se priorizaron publicaciones de 2024 en adelante y estudios de revisión o comparativos. Los metadatos de cada artículo se recuperaron y contrastaron por DOI en Crossref; ninguna referencia se incluyó sin esa verificación.

El proceso fue iterativo. Primero se mapearon las familias de métodos con revisiones generales [1], [5]. Después se incorporó una revisión específica sobre forecasting eléctrico doméstico [6] y estudios comparativos entre enfoques clásicos, de machine learning y de deep learning. El último filtro buscó trabajos de consumo residencial con análisis de interpretabilidad y gestión energética [7], [8], [9], evitando antecedentes recientes pero periféricos al problema.

6. Estado del arte

La previsión de carga eléctrica cuenta con una amplia trayectoria de investigación. Sin embargo, la aparición de nuevos conjuntos de datos y modelos ha mantenido abierto el debate sobre cuáles enfoques son más adecuados para cada contexto. La literatura se organiza aquí en seis bloques que van de lo general a lo específico.

6.1 El problema del forecasting eléctrico

El forecasting de demanda se divide por horizonte en corto, mediano y largo plazo, y por nivel en sistema, regional y de cliente individual. El nivel residencial es el más volátil: depende de hábitos de los ocupantes y del uso discontinuo de los equipos, por lo que los errores relativos suelen ser mayores que en agregados. Las revisiones recientes describen ese abanico de métodos y coinciden en que no hay un ganador universal [1], [6].

6.2 Métodos estadísticos como línea base

Durante décadas dominaron el suavizado exponencial, ARIMA y sus variantes estacionales. Siguen siendo útiles como referencia: son simples, interpretables y baratos de entrenar. Su límite es la linealidad implícita y la estacionalidad fija, supuestos que el consumo residencial real no

respetar. La práctica actual los conserva como baseline para decidir si un modelo complejo justifica su costo [5].

6.3 Machine learning basado en árboles

Los ensambles de árboles se volvieron recurrentes en load forecasting por su capacidad de capturar interacciones no lineales y su robustez ante valores atípicos. Zhang y colaboradores mostraron que una combinación de CatBoost y XGBoost mejora la precisión a corto plazo frente a modelos simples [10]. Lei y colaboradores integraron random forest con una red BiLSTM y un mecanismo evolutivo para consumo de edificios, con resultados superiores a cada modelo por separado [11]. Para datos tabulares con variables temporales codificadas, como los nuestros, estos modelos son candidatos naturales.

6.4 Deep learning para series temporales

Las redes LSTM marcaron un punto de inflexión porque pueden retener dependencias de largo plazo en secuencias. Westphal mostró que una LSTM con especialización posterior al entrenamiento supera de forma consistente a los métodos estadísticos en consumo residencial a corto plazo [12]. Santos y colaboradores compararon transformadores y redes recurrentes y concluyeron que los transformadores rinden bien pero su costo de entrenamiento sigue siendo alto para aplicaciones domésticas [13]. Una vía intermedia son los híbridos: Lu y colaboradores combinaron NeuralProphet con una arquitectura CNN-LSTM y obtuvieron mejoras sobre cada modelo individual [14].

6.5 Modelos híbridos e interpretables

La tendencia más reciente busca precisión sin sacrificar explicabilidad. Manjili y colaboradores combinaron un Temporal Fusion Transformer con XGBoost para demanda agregada [15]. Unlu y colaboradores evaluaron arquitecturas híbridas en condiciones extremas y encontraron que la fusión reduce el error justo en los días atípicos, que es donde más importa [16]. Somasundaram y colaboradores llevaron la idea a operación en tiempo real, integrando previsión de pico y de demanda día a día [17]. Estos trabajos confirman la utilidad de comparar complejidades distintas en lugar de apostar por una sola arquitectura.

6.6 Forecasting residencial y eficiencia energética

El interés por el nivel residencial creció con los medidores inteligentes. La revisión de Ibrahimov y colaboradores (2026) sistematiza los métodos aplicados específicamente a hogares y señala la dispersión de protocolos de evaluación como un problema abierto [6]. Li y colaboradores propusieron un marco para predecir consumo neto incorporando variables exógenas [7]. A escala de vivienda, Banga y colaboradores mostraron que un esquema en dos fases (clasificación más regresión) mejora la precisión [8], y Al-Rajab y colaboradores conectaron la predicción con recomendaciones de eficiencia en un marco llamado Sustainable EnergySense [9]. Ese trabajo importa porque muestra que acompañar la predicción con orientación de consumo no es nuevo; ElecPrevis lo retoma con un protocolo de evaluación único, análisis de submediciones y escenarios de reducción definidos con claridad.

6.7 Aplicaciones en renovables, redes y movilidad eléctrica

Más allá del hogar, los mismos modelos sostienen aplicaciones de Industria 4.0: previsión en sistemas con alta penetración renovable [18], enfoques bioinspirados para previsión en tiempo real [19] y control predictivo de carga de vehículos eléctricos con modelos híbridos [20]. Pueden no ser el centro de ElecPrevis, pero muestran la relevancia del forecasting en la operación moderna de la energía.

6.8 Síntesis de las familias de métodos

La tabla siguiente resume ventajas y límites de cada familia y cómo se usará en el proyecto:

Familia	Ventajas	Límites	Papel en ElecPrevis
Estadísticos (ARIMA, suavizado)	Simples, interpretables, baratos	Linealidad y estacionalidad fija; fallan en series no lineales	Referencia conceptual y baseline teórico
Machine learning (RF, XGBoost)	Capturan no linealidad; robustos a atípicos; buenos con tabulares	Exigen ingeniería de variables; no modelan la secuencia por sí solos	Dos de los cuatro modelos comparados
Deep learning (LSTM)	Modelan dependencias largas en secuencias	Entrenamiento costoso; más hiperparámetros	El modelo secuencial de la comparación
Híbridos (TFT+XGB, CNN-LSTM)	Precisión y robustez en días atípicos	Complejidad alta; difícil interpretación	Referencia de frontera, no se implementa en el Hito 2

Tabla 3. Síntesis comparativa de familias de métodos.

6.9 Matriz de antecedentes

La matriz condensa los antecedentes más cercanos al problema. Se incluyen estudios que trabajan a nivel residencial o de edificio, porque son los que definen la brecha real:

Autor / Año	Problema	Algoritmo	Resolución / horizonte	Resultado principal	Limitación que motiva nuestro trabajo
Ibrahimov et al. / 2026	Revisión de forecasting eléctrico doméstico	Revisión de ML y DL	Múltiples	Mapa de métodos y vacíos de evaluación	No propone un flujo reproducible único
Banga et al. / 2024	Consumo residencial a corto plazo	Híbrido en dos fases	Horaria / 1 h	Mejora a nivel de vivienda	Sin análisis de submediciones
Al-Rajab et al. / 2024	Consumo residencial y eficiencia	Pipeline ML	No reportada	Recomendaciones de eficiencia	Sin comparación formal de modelos
Li et al. / 2024	Predicción de consumo neto	ML con variables exógenas	Horaria	Mejora sobre líneas base	Dataset y protocolo distintos
Zhang et al. / 2024	Previsión a corto plazo	CatBoost + XGBoost	Horaria	Mejora frente a modelos simples	Enfoque en sistemas, no en hogar
Lei et al. / 2024	Consumo de edificios	RF + SSA + BiLSTM	Horaria	Alta precisión evolutiva	Edificios, no residencial individual

Westphal / 2025	Consumo residencial con DL	LSTM especializada	Horaria / corto plazo	Supera a los estadísticos	Un solo perfil de vivienda
Lu et al. / 2024	Previsión robusta a corto plazo	NeuralProphet + CNN-LSTM	Horaria	Mejora híbrida	Sin submediciones internas
Unlu et al. / 2025	Previsión en condiciones extremas	Híbridos DL	Horaria	Menor error en días atípicos	Datos agregados
Manjili et al. / 2026	Previsión interpretable	TFT + XGBoost	Agregada	Precisión con explicabilidad	Escala no residencial

Tabla 4. Matriz de antecedentes.

6.10 Brecha de conocimiento y contribución del proyecto

La revisión muestra que el forecasting residencial ya tiene literatura propia y resultados sólidos. Aunque existe una cantidad considerable de estudios sobre hogares, comparar sus resultados es difícil: usan datasets, resoluciones, horizontes y protocolos de evaluación distintos, de modo que no se puede saber con claridad cuándo un modelo complejo justifica su costo frente a uno simple. Tampoco es común que el análisis baje hasta las submediciones y traduzca el resultado en escenarios que un usuario entienda.

ElecPrevis no propone un algoritmo nuevo. El aporte está en tres decisiones metodológicas: comparar regresión lineal, random forest, XGBoost y LSTM con la misma resolución de 30 minutos, el mismo horizonte y el mismo protocolo de validación temporal, algo que la literatura señala como necesario pero poco practicado [6]; analizar las submediciones para explicar el consumo por grupos de cargas; y simular escenarios de reducción con supuestos claros, sin presentarlos como efectos causales comprobados.

7. Marco teórico / conceptual

Este marco reúne los conceptos necesarios para entender el problema, justificar el diseño y soportar la solución. Los conceptos incluidos se seleccionaron por su relación directa con las etapas posteriores del proyecto.

7.1 Consumo eléctrico y el dataset UCI

El consumo de un hogar se mide con potencia activa (kW), potencia reactiva (kVAR), tensión (V) e intensidad (A). La potencia activa es la que se convierte en trabajo útil (luz, calor, movimiento) y la que factura la empresa prestadora. El dataset UCI registró estas variables minuto a minuto en una vivienda de Sceaux entre diciembre de 2006 y noviembre de 2010 [4].

Además de las variables globales, hay tres submediciones: una asociada a la cocina, otra a la lavandería y otra al calentamiento de agua y al aire acondicionado. Conviene llamarlas submediciones o circuitos, no zonas del hogar: cada una agrupa ciertos equipos, no la totalidad de lo que ocurre en un espacio. Esta distinción importa a la hora de interpretar resultados y de no sobrevender las recomendaciones.

El archivo original marca los valores faltantes con el carácter "?". Son aproximadamente 1,25 % de las celdas y se concentran en algunos períodos. Es un problema real que obliga a documentar la imputación durante el ETL.

7.2 Series temporales y estacionalidad

Una serie temporal es una secuencia de observaciones ordenadas en el tiempo. El consumo eléctrico se describe con tres componentes: tendencia (T), estacionalidad (S) y residuo (R), que en forma aditiva se expresan como:

$$Y(t) = T(t) + S(t) + R(t)$$

La estacionalidad domina este dominio: ciclos por hora (picos de mañana y noche), por semana (fin de semana frente a días laborales) y por estación del año. La descomposición de la serie será el primer análisis exploratorio y orientará la construcción de variables.

7.3 Horizonte de predicción y resolución temporal

Para este proyecto se trabajará con intervalos de 30 minutos y con un horizonte de predicción de un paso. Estas dos decisiones determinan la forma en que se construirá la variable objetivo. La variable objetivo será la potencia activa media del siguiente intervalo, y el intervalo base será de 30 minutos. Es decir, un horizonte de un paso (one-step ahead): [6]

$$\hat{y}(t+1) = f(y(t), y(t-1), \dots, y(t-L), X(t))$$

donde L es el número de rezagos y X(t) agrupa variables temporales (hora, día de la semana, mes) y submediciones pasadas. Para la aplicación se encadenarán varias predicciones de un paso, generando así una vista del día siguiente sin cambiar el horizonte del modelo. Esta distinción evita la ambigüedad entre "predecir la próxima hora" y "predecir el día completo", que son cosas distintas.

7.4 Rezagos y ventana deslizante

Con resolución de 30 minutos, los rezagos útiles se derivan de los ciclos del consumo: el rezago 1 captura el intervalo inmediatamente anterior, el 48 el mismo punto del día previo y el 336 el mismo punto de la semana anterior. A ellos se suman medias móviles y variables calendario. Los rezagos se construirán únicamente con información disponible hasta el momento de la predicción. El uso de valores futuros introduciría data leakage y produciría métricas artificialmente optimistas.

7.5 Modelos de regresión supervisada

El problema se formula como regresión: dado un vector de características, se predice un valor continuo. Se compararán cuatro modelos, elegidos porque representan niveles de complejidad crecientes y porque todos pueden entrenarse con el mismo flujo de datos.

Regresión lineal. Supone una relación lineal entre características y objetivo. Es el modelo más simple y el primero del curso; funciona como línea base para decidir si la complejidad adicional vale la pena.

$$y = \beta_0 + \beta_1 \cdot x_1 + \dots + \beta_n \cdot x_n + \varepsilon$$

Random forest. Entrena muchos árboles de decisión sobre submuestras con reposición y promedia sus predicciones. Ese promedio reduce la varianza sin aumentar el sesgo, lo que lo hace robusto ante atípicos e interacciones complejas [11].

XGBoost. Es boosting de árboles: cada árbol nuevo corrige los errores de los anteriores minimizando una pérdida diferenciable con regularización [10]. Suele estar entre los mejores modelos en datos tabulares y será un candidato fuerte.

Redes LSTM. Arquitectura recurrente con puertas que deciden qué información del pasado conservar. Puede modelar dependencias largas en secuencias, a cambio de mayor costo de entrenamiento [12]. La puerta de olvido se describe como:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

7.6 Validación temporal y prevención de data leakage

En series temporales no se puede partir la muestra al azar. Una validación cruzada aleatoria tradicional mezclaría observaciones futuras dentro del entrenamiento, y las métricas resultarían optimistas sin reflejar el desempeño real. Por eso se usará validación temporal: se entrena con los primeros períodos y se prueba con los últimos, respetando el orden cronológico. Cuando el volumen lo permita, se usará walk-forward validation (ventana en expansión o deslizante), que simula cómo operaría el modelo si se reentrenara periódicamente [5].

En un problema de regresión, además, hablar de dataset "balanceado" requiere matiz. No hay clases que equilibrar como en clasificación. La lectura correcta es de cobertura: que la serie conserve todos los períodos del día, los días de la semana y las estaciones, que no se pierdan sistemáticamente ciertos bloques horarios y que el corte de validación preserve esa representatividad. Esa interpretación se documentará en el Entregable 2.

7.7 Métricas de evaluación

Se usarán cuatro métricas, cada una con una lectura distinta del error:

MAE (error absoluto medio): interpretable en kW, no sobredimensiona errores grandes.

$$\text{MAE} = (1/n) \cdot \sum |y_i - \hat{y}_i|$$

RMSE (raíz del error cuadrático medio): penaliza más los errores grandes, relevantes en picos de consumo.

$$\text{RMSE} = \sqrt{[(1/n) \cdot \sum (y_i - \hat{y}_i)^2]}$$

R²: proporción de la varianza explicada por el modelo, fácil de explicar en una sustentación.

$$R^2 = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$$

sMAPE (error porcentual absoluto medio simétrico): se elige en lugar del MAPE clásico porque el MAPE explota cuando el valor real se acerca a cero, algo frecuente en consumo residencial nocturno.

$$\text{sMAPE} = (100/n) \cdot \sum [2 \cdot |y_i - \hat{y}_i| / (|y_i| + |\hat{y}_i|)]$$

8. Metodología propuesta

El desarrollo sigue la ruta del curso (ETL, visualización, machine learning) en seis fases, cada una asociada a un objetivo específico y a las semanas del cronograma.

Fase 1 · Adquisición y preparación (objetivo 1; semanas 5-6): descarga del dataset UCI, análisis de calidad, tratamiento documentado de valores faltantes, remuestreo a 30 minutos y construcción de variables temporales y rezagadas sin información futura.

Fase 2 · Análisis exploratorio (objetivo 2; semanas 7-8): descomposición de la serie, patrones por hora/día/mes, correlaciones y comportamiento de las tres submediciones.

Fase 3 · Construcción del problema predictivo (objetivo 3; semanas 9-10): definición formal del horizonte de un paso, partición temporal de entrenamiento, validación y prueba, y verificación de que no haya leakage entre ellas.

Fase 4 · Modelado y evaluación (objetivo 3; semanas 10-12): entrenamiento de regresión lineal, random forest, XGBoost y LSTM con walk-forward validation, comparación con MAE, RMSE, R² y sMAPE, y análisis de costo e interpretabilidad.

Fase 5 · Escenarios de eficiencia (objetivo 4; semanas 13-14): análisis de submediciones y simulación de escenarios de reducción con supuestos explícitos, sin atribuir causalidad.

Fase 6 · Aplicación (objetivo 5; semanas 15-16): prototipo que muestre histórico, predicción de los próximos intervalos y escenarios simulados, y redacción del artículo.

9. Alcance y limitaciones

9.1 Alcance

El proyecto cubre un pipeline completo de ciencia de datos sobre el dataset UCI: ingesta, limpieza, remuestreo, análisis exploratorio, modelado comparativo, escenarios de eficiencia y un prototipo. El código se organizará en módulos Python siguiendo las buenas prácticas del curso, y el entregable final incluirá el dataset procesado, los modelos entrenados y las visualizaciones.

9.2 Limitaciones

- Los datos corresponden a una sola vivienda en Francia, entre 2006 y 2010. Los patrones no son generalizables a otros hogares ni a Colombia; la metodología sí lo es.
- Los datos tienen cerca de dos décadas. Los hábitos de consumo y la eficiencia de los equipos cambiaron desde entonces.
- El registro es agregado por vivienda y por tres submediciones de cargas; no hay datos de electrodomésticos individuales.
- No se incorporan variables externas (clima, tarifas, días festivos) en esta versión del análisis.
- Al ser datos observacionales, los escenarios de eficiencia son hipotéticos y no demuestran causalidad.
- La muestra de un hogar convierte el estudio en un caso de aplicación, no en una afirmación poblacional.

Referencias

- [1] B. Biswal et al., "Review on smart grid load forecasting for smart energy management using machine learning and deep learning techniques," *Energy Reports*, vol. 12, pp. 3654-3670, 2024. <https://doi.org/10.1016/j.egyr.2024.09.056>
- [2] M. Casini et al., "Machine Learning and image analysis towards improved energy management in Industry 4.0: a practical case study on quality control," *Energy Efficiency*, vol. 17, no. 5, art. 48, 2024. <https://doi.org/10.1007/s12053-024-10228-7>
- [3] N. Mathangi and S. Malathi, "Role of machine learning and deep learning in optimizing smart home energy management systems: Advancements and technical factors," *Energy Efficiency*, vol. 19, no. 5, art. 38, 2026. <https://doi.org/10.1007/s12053-026-10439-0>
- [4] M. Lichman, "UCI Machine Learning Repository," School of Information and Computer Sciences, University of California, Irvine, CA, USA, 2013. [Online]. Available: <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>
- [5] A. Perçuku et al., "Enhancing Electricity Load Forecasting with Machine Learning and Deep Learning," *Technologies*, vol. 13, no. 2, pp. 59, 2025. <https://doi.org/10.3390/technologies13020059>
- [6] E. Ibrahimov et al., "AI-driven household electricity load forecasting: challenges, methods, and future directions," *Artificial Intelligence Review*, vol. 59, no. 9, art. 190, 2026. <https://doi.org/10.1007/s10462-026-11583-w>
- [7] X. Li et al., "An advanced framework for net electricity consumption prediction: Incorporating novel machine learning models and optimization algorithms," *Energy*, vol. 296, art. 131259, 2024. <https://doi.org/10.1016/j.energy.2024.131259>
- [8] A. Banga and S. Sharma, "Short-Term Electricity Consumption Forecasting at Residential Level Using Two-Phase Hybrid Machine Learning Model," *ELECTRICA*, vol. 24, no. 2, pp. 272-283, 2024. <https://doi.org/10.5152/electrica.2024.22107>
- [9] M. Al-Rajab and S. Loucif, "Sustainable EnergySense: a predictive machine learning framework for optimizing residential electricity consumption," *Discover Sustainability*, vol. 5, no. 1, art. 55, 2024. <https://doi.org/10.1007/s43621-024-00243-0>
- [10] L. Zhang and D. Jánošík, "Enhanced short-term load forecasting with hybrid machine learning models: CatBoost and XGBoost approaches," *Expert Systems with Applications*, vol. 241, art. 122686, 2024. <https://doi.org/10.1016/j.eswa.2023.122686>
- [11] L. Lei et al., "An evolutionary deep learning model based on EWKM, random forest algorithm, SSA and BiLSTM for building energy consumption prediction," *Energy*, vol. 288, art. 129795, 2024. <https://doi.org/10.1016/j.energy.2023.129795>
- [12] I. Westphal, "Short-term load forecasting with deep learning: Improving performance with post-training specialization," *The Electricity Journal*, vol. 38, no. 1, art. 107449, 2025. <https://doi.org/10.1016/j.tej.2024.107449>
- [13] R. P. d. Santos et al., "Deep learning in time series forecasting with transformer models and RNNs," *PeerJ Computer Science*, vol. 11, pp. e3001, 2025. <https://doi.org/10.7717/peerj-cs.3001>

- [14] S. Lu and T. Bao, "Short-Term Electricity Load Forecasting Based on NeuralProphet and CNN-LSTM," IEEE Access, vol. 12, pp. 76870-76879, 2024.
<https://doi.org/10.1109/ACCESS.2024.3407094>
- [15] S. Manjili et al., "Interpretable AI Hybrid Model for Electricity Demand Forecasting: Combining TFT and XGBoost in Smart Grid Data," Computer Modeling in Engineering & Sciences, vol. 147, no. 1, pp. 1-10, 2026. <https://doi.org/10.32604/cmes.2026.076217>
- [16] A. Unlu and M. Peña, "Comparative Analysis of Hybrid Deep Learning Models for Electricity Load Forecasting During Extreme Weather," Energies, vol. 18, no. 12, art. 3068, 2025.
<https://doi.org/10.3390/en18123068>
- [17] V. Somasundaram and K. Jothinathan, "Real-time efficient short-term peak load and day-ahead electricity load forecasting system using machine learning approach," Energy, vol. 342, art. 139508, 2026. <https://doi.org/10.1016/j.energy.2025.139508>
- [18] A. Franco and C. Pagliantini, "Forecasting Electricity Demand in Renewable-Integrated Systems: A Case Study from Italy Using Recurrent Neural Networks," Electricity, vol. 6, no. 2, pp. 30, 2025.
<https://doi.org/10.3390/electricity6020030>
- [19] M. Y. Cheng and Q. T. Vu, "Bio-inspired bidirectional deep machine learning for real-time energy consumption forecasting and management," Energy, vol. 302, art. 131720, 2024.
<https://doi.org/10.1016/j.energy.2024.131720>
- [20] G. McClone et al., "Hybrid Machine Learning Forecasting for Online MPC of Work Place Electric Vehicle Charging," IEEE Transactions on Smart Grid, vol. 15, no. 2, pp. 1891-1901, 2024.
<https://doi.org/10.1109/TSG.2023.3296014>